Итоговый проект Data Analyst

Анализ эффективности маркетинговых кампаний магазина спортивных товаров

Аналитический отчёт

Подготовка данных • A/B тестирование
Сегментация клиентов • Прогнозирование покупок

Резюме для руководителя

Рекомендуется проверить персональные предложения в новом A/B-тесте с оценкой прибыли, использовать шесть сегментов для выбора механики и ранжировать аудиторию города 1188 по модели Random Forest. Выручка на клиента в первой кампании выше на 18,61%; в Top 5% модель находит 37,5% покупателей тестовой выборки. Масштабирование требует проверки маржинальности и ограничений контрольной группы.

1. Цель проекта

Цель проекта - проанализировать данные о клиентах и их покупках, оценить эффективность маркетинговых активностей и определить подходы, которые могут повысить результативность будущих кампаний.

В рамках исследования были решены пять основных задач: подготовка и очистка данных, восстановление утерянного признака пола клиентов, анализ первой маркетинговой кампании с помощью A/B-тестирования, сегментация клиентской базы и построение модели склонности клиента к покупке.

Основной результат проекта заключается в том, что маркетинговую работу с клиентской базой целесообразно строить не одинаково для всей аудитории, а с учётом клиентских сегментов, предыдущего покупательского поведения и прогнозируемой склонности к покупке.

2. Ключевые результаты

Исследование показало, что первая персональная маркетинговая кампания оказала заметное влияние на поведение клиентов. В тестовой группе выручка на пользователя была примерно на 18,6% выше, а количество покупок на пользователя - примерно на 25% выше, чем в контрольной группе. При этом средний чек снизился примерно на 6,1%, а конверсия - примерно на 4,19 процентного пункта. Таким образом, положительный эффект кампании был связан прежде всего с увеличением частоты покупок.

Кластеризация позволила выделить шесть содержательно различающихся клиентских сегментов: клиентов с преимущественным интересом к мужским товарам, скидочно-чувствительную аудиторию с интересом к женским товарам, высокоактивных постоянных клиентов, низкоактивных покупателей преимущественно универсальных товаров, молодую аудиторию и высокочековый сегмент.

Для жителей города 1188 была построена модель склонности к покупке выбранного целевого товара. Лучший результат показал Random Forest. ROC-AUC модели составил 0,8863, PR-AUC - 0,0643. При выборе 5% клиентов с наибольшей прогнозируемой склонностью модель позволила охватить 37,5% всех фактических покупателей в тестовой выборке, а при выборе 20% аудитории - 81,25%.

Полученные результаты позволяют использовать модель не как жёсткий классификатор «купит / не купит», а как инструмент ранжирования клиентов для более точного распределения маркетингового бюджета.

3. Описание данных и подготовка

Исходные данные включали информацию о клиентах, их социально-демографических характеристиках, персональных коэффициентах и покупках. В соответствии с условиями задания дальнейший анализ проводился только для клиентов страны с кодом 32. Это требование напрямую указано в исходном задании.

Первоначально в базе содержалось 104 989 уникальных клиентов. Для 89 241 клиента пол был известен, а для 15 748 значение признака gender было утеряно.

После обязательной фильтрации по стране 32 осталось 104 437 клиентов, из которых:

- 88 786 клиентов имели известный пол;
- 15 651 клиент имел утерянное значение пола.

На этапе предобработки были проверены дубликаты, пропущенные значения, категориальные признаки и диапазоны числовых значений.

Особое внимание было уделено таблице покупок. В ней были выявлены четыре записи с отрицательной стоимостью -30. Поскольку корректное значение цены невозможно было восстановить на основании других данных, а количество таких строк было крайне мало по сравнению с общим объёмом датасета, записи были исключены из дальнейшего анализа.

Названия товаров были нормализованы по регистру и пробелам. Пропуски в цветах были заменены технической категорией unknown. Для составных цветов были дополнительно сформированы признаки количества цветов, наличия нескольких цветов и основного цвета. Пропуски в признаке гендерной принадлежности товара были вынесены в отдельную категорию.

В результате была получена очищенная таблица покупок, пригодная для формирования клиентских агрегатов.

4. Восстановление утерянного пола клиентов

Для восстановления признака gender была поставлена задача бинарной классификации.

В качестве признаков использовались возраст клиента, уровень образования, город проживания и персональный коэффициент personal_coef. Технический идентификатор id в модель не включался. Признак страны также не использовался, поскольку после фильтрации принимал одинаковое значение 32 для всех клиентов.

Были протестированы несколько подходов: Dummy Classifier, Logistic Regression и Random Forest.

Лучший результат показал Random Forest:

- Accuracy ≈ 0,9960;
- Precision ≈ 0,9931;
- Recall = 1,0000;
- F1 ≈ 0,9965.

Для проверки устойчивости результата дополнительно была проведена стратифицированная 5-fold cross-validation. Среднее значение F1 составило около 0,9977 при стандартном отклонении около 0,0005. Низкий разброс между фолдами показывает, что высокая метрика не является результатом удачного случайного разбиения данных.

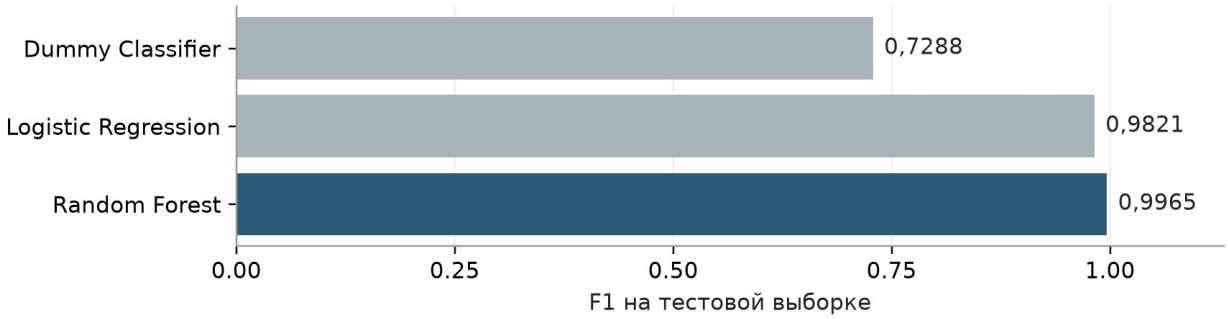
Отдельно была исследована роль признака personal_coef. Без него F1 Random Forest снизился примерно до 0,689. Это показывает, что персональный коэффициент является ключевым предиктором для восстановления пола.

После проверки качества финальная модель была обучена на всех клиентах с известным полом и использована для восстановления gender у 15 651 клиента.

После объединения исходных и восстановленных данных была сформирована единая клиентская таблица из 104 437 клиентов страны 32 без пропусков в персональных признаках.

Вывод: задача восстановления утерянного пола решена с высокой и устойчивой точностью. Итоговый датасет может использоваться в последующих этапах анализа.

Рисунок 1. Качество восстановления пола клиентов



Random Forest даёт F1 = 0,9965. Средний F1 на пяти фолдах - 0,9977 (стандартное отклонение 0,0005); результат устойчив к разбиению выборки.

Источник: сохранённые результаты сравнения классификаторов и 5-fold cross-validation в ноутбуке.

5. Формирование клиентской витрины

Для последующего анализа покупки были агрегированы до уровня клиента.

Для каждого клиента были сформированы показатели покупательской активности и поведения:

количество покупок, общая сумма расходов, средний и медианный чек, минимальный и максимальный чек, количество уникальных товаров и цветов, число активных дней, первый и последний день покупки, recency, доля покупок со скидкой, доля мультицветных товаров, доли женских, мужских и универсальных товаров, наиболее часто встречающийся цвет и наиболее частая гендерная категория товара.

Покупательские агрегаты были объединены с очищенными персональными данными.

Полученная клиентская витрина стала основой для A/B-тестирования, кластеризации и дальнейшего моделирования.

6. Анализ первой маркетинговой кампании

Первая маркетинговая кампания проводилась с 5-го по 16-й день и представляла собой персональное предложение клиентам через email-рассылку. По условиям задания для оценки её эффективности была сформирована тестовая группа клиентов, получивших предложение, и контрольная группа клиентов со схожими характеристиками, которым предложение не предоставлялось.

Для сравнения групп были рассчитаны основные бизнес-метрики и проведены статистические тесты.

По сравнению с контрольной группой в тестовой группе были получены следующие изменения:

- конверсия снизилась примерно на 4,19 процентного пункта;
- средний чек покупателей снизился примерно на 6,10%;
- количество покупок на пользователя увеличилось примерно на 25%;
- выручка на пользователя выросла примерно на 18,61%.

Все рассмотренные различия оказались статистически значимыми при уровне значимости 0,05.

Полученный результат показывает, что персональная кампания не увеличила средний чек, однако стимулировала клиентов совершать покупки чаще. За счёт роста частоты покупок итоговая выручка на одного клиента увеличилась.

При интерпретации результата необходимо учитывать, что конверсия контрольной группы составила 100%. Это является необычной особенностью сформированной контрольной выборки и ограничивает прямую интерпретацию показателя конверсии. Перед повторным запуском следует проверить формирование групп и включение клиентов без покупок; статистическая значимость сама по себе не устраняет возможное смещение выборки.

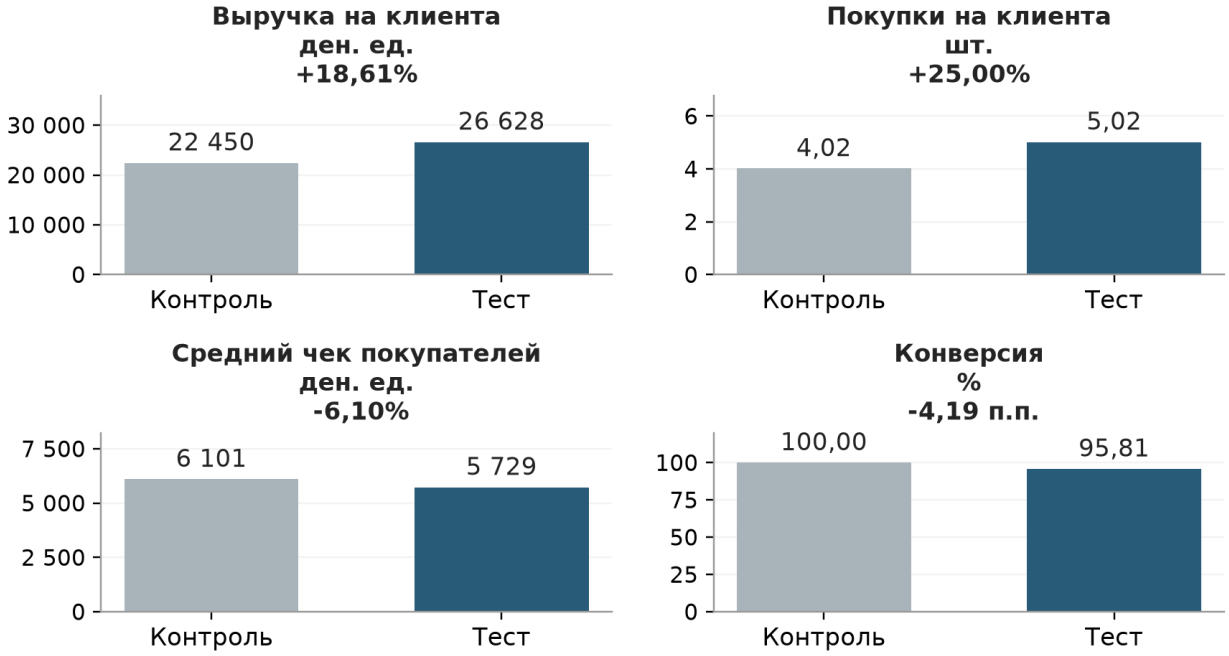
6.1 Бизнес-вывод

С точки зрения выручки первая кампания выглядит эффективной и может рассматриваться как перспективная механика.

Однако перед масштабированием необходимо оценить не только рост выручки, но и изменение прибыли. Персональная скидка способна снижать маржинальность, поэтому увеличение оборота само по себе не гарантирует роста финансового результата.

Рекомендуется повторно протестировать механику на новой аудитории и дополнительно анализировать прибыль на пользователя.

Рисунок 2. Результаты первой кампании за дни 5-16



Рост числа покупок сопровождается повышением выручки на клиента. Средний чек и конверсия ниже; контрольная конверсия 100% требует проверки состава групп.

Источник: ab_summary и ab_effects. Контроль: 4 960 клиентов; тест: 4 984. Шкалы панелей независимы. Средний чек - среднее клиентских средних чеков среди покупателей; денежная единица в данных не уточнена.

7. Сегментация клиентской базы

Для более персонализированной работы с клиентами была проведена кластеризация.

В модель сегментации были включены признаки, характеризующие социально-демографические характеристики и покупательское поведение: возраст, персональный коэффициент, количество покупок, общая сумма расходов, средний чек, количество уникальных товаров, число активных дней, доля покупок со скидкой, recency, предпочтения по гендерной категории товара и доля мультицветных товаров.

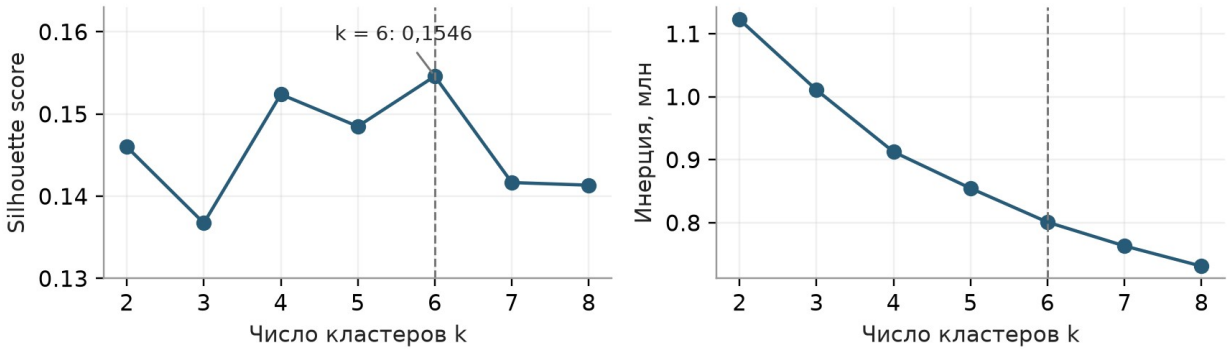
Для денежных и частотных признаков с сильной асимметрией применялось преобразование log1p, после чего данные стандартизировались.

Количество кластеров оценивалось по методу локтя, silhouette score и бизнес-интерпретируемости.

Максимальный silhouette score среди рассмотренных вариантов был получен при k = 6 и составил около 0,155. При k = 4 значение составляло около 0,152, поэтому математическое преимущество шести кластеров было небольшим. Тем не менее разделение на шесть сегментов позволило получить более содержательные и полезные для бизнеса клиентские группы.

Невысокий абсолютный silhouette score показывает, что клиентская база не делится на полностью изолированные естественные группы. Поэтому сегментацию следует использовать как практический инструмент для маркетинга, а не как строгое доказательство существования шести объективных типов покупателей.

Рисунок 3. Выбор числа клиентских сегментов



При k = 6 silhouette максимален (0,1546), но близок к k = 4 (0,1524). Шесть сегментов выбраны с учётом бизнес-интерпретируемости; разделение групп слабое.

Источник: cluster_results; k от 2 до 8. Инерция приведена в миллионах единиц критерия.

7.1 Полученные сегменты

Кластер 0 - мужская категория, умеренная активность. Клиенты имеют выраженное предпочтение мужских товаров и среднюю покупательскую активность. Для сегмента подходят персональные подборки мужских категорий, cross-sell и умеренные скидочные механики.

Кластер 1 - женская категория, скидочно-чувствительные. Клиенты чаще других покупают женские товары и характеризуются высокой долей покупок со скидкой. Для них целесообразно использовать промокоды, персональные скидки и краткосрочные акции, одновременно контролируя маржинальность.

Кластер 2 - высокоактивные постоянные клиенты. Это один из наиболее ценных сегментов: высокая частота покупок, высокие совокупные расходы и небольшое значение recency. Основные инструменты - программы лояльности, персональные рекомендации, VIP-механики, cross-sell и up-sell. Избыточные скидки для этой группы нежелательны.

Кластер 3 - низкоактивные, преимущественно унисекс. Клиенты совершают мало покупок и имеют относительно низкие расходы. Для сегмента подходят реактивационные кампании, универсальные товары и простые стимулирующие механики.

Кластер 4 - молодая аудитория. Сегмент имеет существенно более молодой возрастной профиль. Рекомендуется использовать более доступные по цене предложения, популярные модели, спортивные категории и адаптированные каналы коммуникации.

Кластер 5 - высокочековые клиенты. Характеризуется наиболее высоким средним чеком и относительно низкой зависимостью от скидок. Для этой аудитории предпочтительны премиальные предложения, персональные рекомендации, эксклюзивные товары и up-sell вместо массового снижения цены.

7.2 Итог сегментации

Кластеризация показала, что клиенты отличаются не только по объёму расходов и активности, но и по отношению к скидкам, товарным предпочтениям и частоте взаимодействия с магазином.

Это даёт возможность перейти от единой массовой маркетинговой стратегии к сегментному подходу.

Таблица 1. Ключевые характеристики шести сегментов

Кластер	Покупок, шт.	Расходы, ден. ед.	Чек, ден. ед.	Со скидкой, %	Recency, дни	Товарные предпочтения
0 Мужские товары	4,14	21 808	5 543	34	20,05	Мужские 82%
1 Женские товары	5,45	20 241	3 990	44	18,48	Женские 76%
2 Постоянные	18,62	93 599	5 004	37	8,55	Унисекс 40%, мужские 38%
3 Низкая активность	3,80	8 818	2 508	26	21,27	Унисекс 79%
4 Молодые	5,58	30 925	5 955	33	19,01	Унисекс 42%, мужские 37%
5 Высокий чек	5,08	63 036	13 866	18	17,47	Унисекс 68%

Постоянные клиенты (кластер 2) лидируют по активности и расходам, высокочековые (5) - по чеку. У кластера 1 максимальная доля покупок со скидкой; это наблюдаемое поведение, а не оценка причинного эффекта скидки.

Источник: final_cluster_profile. Покупки, расходы, чек, recency и доли усреднены по клиентам; суммы округлены до целых. Recency - число дней после последней покупки, меньше означает более недавнюю покупку.

8. Модель склонности клиента к покупке

Последний этап проекта был посвящён построению модели склонности к покупке для жителей страны 32 и города 1188, на которых планируется новая маркетинговая кампания. Такая задача отдельно указана в условиях проекта.

В качестве целевого товара был выбран **«лиф женский joss»**.

Всего в городе 1188 было 12 438 клиентов. В будущем периоде целевой товар приобрели 64 клиента, что составляет около 0,515% аудитории.

Положительный класс оказался крайне малочисленным, поэтому обычная accuracy не могла использоваться как основная метрика качества.

Для предотвращения утечки данных было сделано временное разделение:

- дни 0-44 использовались для построения признаков;
- дни 45-58 использовались для определения target.

Target принимал значение 1, если клиент купил целевой товар в будущем периоде, и 0 - в противном случае.

Такой подход позволяет моделировать реальную бизнес-ситуацию: на момент запуска кампании используются только сведения, которые уже известны.

Для 240 клиентов отсутствовала история покупок в периоде 0-44. Они не были удалены из выборки, поскольку отсутствие истории само по себе является полезной характеристикой. Более того, один из этих клиентов впоследствии приобрёл целевой товар.

После подготовки признаков датасет был разделён на train и test со стратификацией. В обучающей части оказалось 48 положительных наблюдений, в тестовой - 16.

Были протестированы Logistic Regression и Random Forest.

Рисунок 4. Качество ранжирования клиентов города 1188



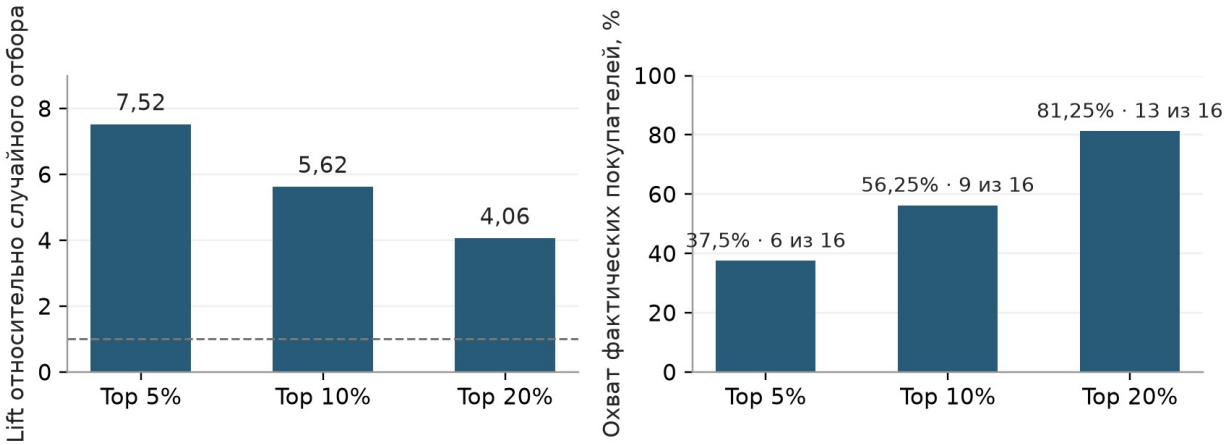
Random Forest превосходит Logistic Regression по обеим метрикам. При редких покупках PR-AUC нужно рассматривать вместе с Lift и охватом покупателей.

Источник: результаты propensity-моделей на одной тестовой выборке: 3 110 клиентов, 16 покупателей. PR-AUC в ноутбуке рассчитан как Average Precision. Шкалы панелей различаются.

8.1 Выбор модели и аудитории

Для сравнения, Lift Logistic Regression в Top 5%, Top 10% и Top 20% составляет 3,76; 3,12 и 2,19. Random Forest лучше концентрирует покупателей в верхней части рейтинга (рисунок 5).

Рисунок 5. Lift и охват покупателей для Random Forest



Top 5% даёт максимальную концентрацию покупателей (Lift 7,52). Расширение отбора до Top 20% повышает охват до 81,25%, снижая концентрацию до Lift 4,06.

Источник: rf_results, тестовая выборка. Размеры отбора: 155 / 311 / 622 клиента; найдено 6 / 9 / 13 из 16 покупателей. Пунктир: Lift = 1 при случайном отборе.

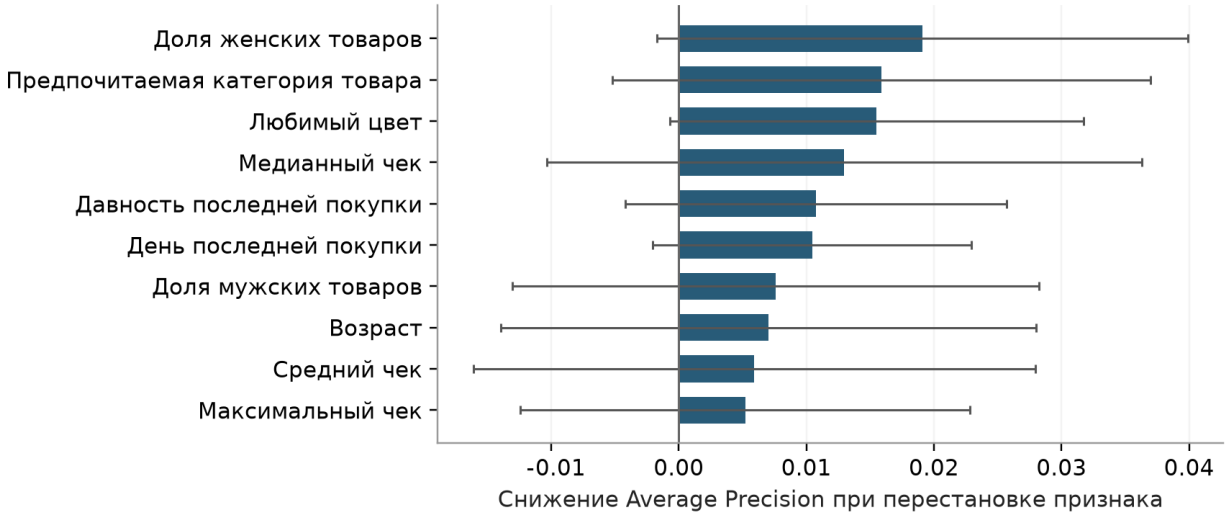
8.2 Использование модели

При стандартном пороге 0,5 Random Forest не показывает высокого recall положительного класса. Однако для рассматриваемой маркетинговой задачи основная ценность модели заключается не в бинарной классификации, а в ранжировании аудитории.

Если бизнес располагает бюджетом только на ограниченное число коммуникаций, модель позволяет направить их клиентам, среди которых вероятность встретить будущего покупателя значительно выше среднего.

8.3 Важность признаков

Рисунок 6. Top-10 признаков модели склонности



Наибольшая средняя важность у доли женских товаров и товарных предпочтений. Большой разброс ограничивает уверенность в порядке признаков; график не показывает направление влияния на покупку.

Источник: feature_importance; метрика Average Precision, 20 перестановок. Отрезки - ±1 стандартное отклонение по перестановкам, не доверительные интервалы.

8.4 Ограничение

В тестовой выборке было только 16 положительных наблюдений. Поэтому значения метрик могут заметно меняться при новом разбиении или на новых данных.

Модель рекомендуется дополнительно валидировать после запуска кампании и регулярно переобучать по мере накопления новых покупок.

9. Итоговые бизнес-рекомендации

Проведённый анализ показывает, что магазину целесообразно постепенно переходить от массовых маркетинговых коммуникаций к сегментному и персонализированному подходу.

Первую персональную кампанию можно рассматривать как успешную с точки зрения роста выручки и количества покупок на клиента. Однако перед масштабированием необходимо оценивать влияние скидки на прибыль и маржинальность.

Для клиентской базы рекомендуется использовать разные механики в зависимости от сегмента. Высокоактивных и высокочековых клиентов следует удерживать через сервис, рекомендации и программы лояльности, не используя лишние скидки. Скидочно-чувствительной аудитории, напротив, можно предлагать промокоды и ограниченные по времени акции. Низкоактивным клиентам нужны отдельные реактивационные сценарии.

При планировании кампании в городе 1188 модель Random Forest рекомендуется использовать для ранжирования клиентов. В зависимости от бюджета маркетинговая коммуникация может быть направлена, например, на верхние 5-20% клиентов по прогнозируемой склонности к покупке.

Наиболее перспективным вариантом является связка:

сегмент клиента → история покупок → прогноз склонности → персональное предложение → последующий A/B-тест.

Такой цикл позволит не только повысить точность выбора аудитории, но и регулярно проверять, действительно ли маркетинговые действия создают дополнительный эффект.

10. Ограничения исследования

Во-первых, необычно высокая конверсия контрольной группы в A/B-тесте требует осторожности при интерпретации этого показателя.

Во-вторых, silhouette score кластеризации составляет около 0,155, поэтому клиентские сегменты нельзя считать полностью естественно отделёнными друг от друга.

В-третьих, модель склонности к покупке обучалась на сильно несбалансированном target: только 64 из 12 438 клиентов приобрели выбранный товар в будущем периоде. Особенно мало положительных наблюдений оказалось в тестовой части - 16 человек.

В-четвёртых, текущий анализ оценивает главным образом покупательское поведение и выручку. Для окончательных решений о масштабировании маркетинговых активностей необходимо учитывать себестоимость скидок, маржу и стоимость коммуникаций.

11. Заключение

Проект охватил подготовку данных, восстановление пола, оценку кампании, сегментацию и прогнозирование покупок. Практический результат - основа для адресного маркетинга с последующей проверкой эффекта в A/B-тестах.